© 2026 Gonzalo Mauricio De la Rivera Arellano · Apache 2.0

# Informe técnico PNLIO: kernel de coherencia v3 y PAO v1.4

Autor y responsable: Gonzalo Mauricio De la Rivera Arellano · 25 de octubre de 2026 · versión corregida
Licencia de los archivos: Apache License 2.0

## 1. Resumen

Este informe describe **dos módulos distintos** del proyecto PNLIO: un kernel que mide qué tan ordenado está un texto (v3) y un módulo que mide estructura temporal en una serie de similitudes entre respuestas (PAO v1.4). Ambos son implementaciones de referencia pequeñas, con medición limitada y sin uso en producción. Se separa en cada caso lo que el código hace por construcción, lo que se midió al ejecutarlo y lo que sigue siendo hipótesis. Ambos módulos solo recomiendan; las decisiones las toma una persona identificable.

## 2. Los dos módulos

| | Kernel de coherencia v3 | PAO v1.4 |
|---|---|---|
| Archivo | pnlio_coherence_kernel_v3.py | pao_pnlio_v1_4.py |
| Qué calcula | Entropía condicional de bigramas H1 y RCR = baseline / (H1 + ruido) sobre un texto | Similitud coseno entre respuestas, media móvil $C_t$, patrón Reflex, entropía de Shannon por turno, contraste por permutaciones |
| Entrada | Un texto de al menos 300 caracteres | Una serie de similitudes (una por turno) |
| Salida | Recomendación de aceptar o rechazar | T (turnos con Reflex) y valor p; recomendación de autorregulación |
| Gobernanza en el código | Responsable obligatorio, registro encadenado por hash, decisión humana registrada, interruptor de detención | Responsable obligatorio; solo recomienda |

## 3. Kernel de coherencia v3

### 3.1 Diseño

$H1 = H(X_t \mid X_{t-1})$ en bits, sobre pares consecutivos de caracteres. A diferencia de la entropía de caracteres, depende del orden: un texto y su versión barajada tienen la misma entropía de caracteres, pero distinta H1. El umbral se calibra con datos (punto medio entre el peor texto legítimo y el mejor ruido). Bajo 300 caracteres el kernel devuelve NO_EVALUABLE.

### 3.2 Medición

Texto natural: 5 párrafos en español de 401 a 449 caracteres, recortados al largo de cada fila. Ruido: cadenas aleatorias del mismo largo; 20 semillas (0 a 19) **de ruido**, con los mismos 5 textos en todas. Barajados: cada texto mezclado una vez por semilla, contado contra el umbral de esa semilla.

| Largo | Ruido | Mín. legítimo (RCR) | Máx. ruido (RCR) | Separa (de 20) | Barajados rechazados |
|---|---|---|---|---|---|
| 160 | mayúsculas+dígitos | 0.373 | 0.435 | 0 | 100 de 100 (*) |
| 160 | mismo alfabeto | 0.373 | 0.380 | 0 | 100 de 100 (*) |
| 300 | mayúsculas+dígitos | 0.340 | 0.323 | 20 | 100 de 100 |
| 300 | mismo alfabeto | 0.340 | 0.296 | 20 | 100 de 100 |

© 2026 Gonzalo Mauricio De la Rivera Arellano · Apache 2.0

| Largo | Ruido | Mín. legítimo (RCR) | Máx. ruido (RCR) | Separa (de 20) | Barajados rechazados |
|---|---|---|---|---|---|
| 400 | mayúsculas+dígitos | 0.329 | 0.289 | 20 | 100 de 100 |
| 400 | mismo alfabeto | 0.329 | 0.270 | 20 | 100 de 100 |

(*) A 160 caracteres la calibración no separa legítimos de ruido, así que ese rechazo de barajados no es confiable.

Una primera corrida con largos 500 y 1000 se descartó: los párrafos no llegaban a 500 caracteres y se compararon contra ruido de 1000.

Demostración del kernel v3 (semilla 42, 4 párrafos de 400 caracteres, una corrida): calibración con mín. legítimo 0.3292, máx. ruido 0.2882, umbral 0.3087; los 4 legítimos recomiendan aceptar y los 4 barajados rechazar; un texto de 160 caracteres devuelve NO_EVALUABLE; verificar_cadena() pasó de (True, None) a (False, 2) al editar un registro; tras detener(), la evaluación devolvió RECHAZADO_POR_DETENCION.

### 3.3 Lectura prudente

Con esta muestra, desde unos 300 caracteres el kernel separa texto natural en español de ruido aleatorio y de su propia versión barajada. El margen es chico (por ejemplo 0.329 contra 0.289 a 400 caracteres) y la muestra es de 5 párrafos, de modo que las 20 semillas no representan 20 textos distintos. No se puede decir que la separación sea general.

## 4. PAO v1.4

### 4.1 Diseño

El patrón Reflex $R_t$ vale 1 si la media móvil $C_t$ (ventana w) está entre theta = 0.75 y U = 0.90 durante k = 2 turnos consecutivos. La v1.3 lo evaluaba sobre similitudes crudas, contra su propia fórmula; en la v1.4 se evalúa sobre $C_t$ y un pico aislado ya no lo activa (verificado en la autoprueba). Se implementaron coseno de bolsa de palabras (embedder simple, declarado), entropía de Shannon por turno y un contraste por permutaciones. El estadístico es T, el número de turnos con Reflex; la nula es que el orden temporal no importa; $p = (1 + \#\{T^*_b >= T_{obs}\}) / (B + 1)$, con B = 1000. No es bootstrap: se permuta el orden sin remuestrear.

### 4.2 Medición

Una corrida, semilla 42, series **sintéticas** de 30 turnos. La serie A tiene tres bloques de 6 turnos con similitud entre 0.78 y 0.88, separados por 4 turnos entre 0.2 y 0.5. La autoprueba pasó completa.

| Serie | T observado | p |
|---|---|---|
| A: estructurada (bloques en banda) | 11 | 0.0020 |
| B: los mismos valores de A en orden aleatorio | 5 | 0.2927 |
| C: 30 valores uniformes aleatorios | 0 | 1.0000 |

Esto muestra que el contraste detecta la estructura que se puso a propósito en A y no la ve en su versión barajada ni en ruido. No es evidencia sobre conversaciones reales con modelos de lenguaje. Un $p < 0.05$ rechaza que el orden sea irrelevante; no demuestra control, intención ni reproducibilidad.

## 5. Gobernanza

Ambos módulos exigen un responsable identificable y solo producen recomendaciones: la autorregulación de PAO no poda contexto ni cambia parámetros. El registro encadenado por hash y el interruptor de detención pertenecen al kernel v3, no a PAO. La cadena detecta ediciones de registros, pero no impide que alguien reescriba el archivo completo y recalcule los hashes; para eso habría que guardar el último

hash en otro lugar. Los usos que el proyecto no apoya (vigilancia masiva, selección de objetivos, decisión de fuerza letal sin una persona que responda, ataques a población civil) se declaran en GOBERNANZA.md como principio; no son vinculantes por licencia.

## 6. Alcance real y límites

**No detecta mentiras ni desinformación.** H1 mide estructura de caracteres, no veracidad ni intención. Es esperable que un texto falso bien escrito tenga un RCR similar al de uno verdadero, pero esa prueba no se ha hecho. **Distinguir dos narrativas bien escritas** sobre el mismo hecho, una real y otra inventada, sigue siendo hipótesis sin probar. **Las cadenas repetidas** (por ejemplo solo letras A) tienen H1 casi cero y se aceptan: es un filtro de desorden, no de semántica. **La similitud coseno** de bolsas de palabras mide solapamiento de vocabulario: un modelo que repite frases obtiene similitud alta sin comprender, y Reflex alto puede indicar repetición. No se probó nada sobre conciencia ni autopercepción. El umbral de error de 0.15 de la autorregulación no está calibrado.

## 7. Reproducibilidad y pendientes

Semilla 42; numpy solo para PAO. Los dos módulos se ejecutan con python pnlio_coherence_kernel_v3.py y python pao_pnlio_v1_4.py. El script de prueba de 20 semillas que generó la tabla de la sección 3.2 aún no está publicado y conviene subirlo junto al kernel. Pendientes: la prueba de texto verdadero contra falso bien escrito, probar PAO con diálogos reales y varias semillas, y alinear la licencia del README, que todavía menciona MIT en alguna parte, con los archivos, que llevan Apache 2.0 (decisión del autor).